

# NI-AM1

Ondřej Wrzecionko

ZS 2022/2023

## Obsah

<b>1</b>	<b>Úvod</b>	<b>3</b>
1.1	Hodnocení . . . . .	3
1.2	Plán . . . . .	3
1.3	Middleware . . . . .	3
<b>2</b>	<b>Architektury informačních systémů</b>	<b>4</b>
2.1	Přehled . . . . .	4
2.2	Funkce a procesy . . . . .	5
2.3	Data . . . . .	5
2.4	Integrace aplikací . . . . .	6
2.5	Softwarové architektury . . . . .	6
2.6	Typy middlewarů . . . . .	7
<b>3</b>	<b>Architektura služeb</b>	<b>8</b>
3.1	Pohledy na službu . . . . .	8
3.2	Rozhraní, popis a implementace . . . . .	8
3.3	Public Process . . . . .	8
3.4	Principy služeb . . . . .	8
3.5	Integrace a interoperabilita . . . . .	9
3.6	SOA . . . . .	9
3.7	ESB . . . . .	9
3.8	Integrační vzory . . . . .	10
3.9	Datové transformace . . . . .	10
3.10	Škálovatelnost . . . . .	10
<b>4</b>	<b>Aplikační protokoly</b>	<b>11</b>
4.1	Socket . . . . .	11
4.2	Metriky . . . . .	11
4.3	Adresace . . . . .	11
4.4	HTTP . . . . .	11
4.5	HTTP Keep-alive . . . . .	11
4.6	HTTP pipelining . . . . .	12
4.7	Domain sharding . . . . .	12

4.8	State management . . . . .	12
4.9	SOAP . . . . .	12
4.10	WSDL . . . . .	12
<b>5</b>	<b>Architektura aplikačního serveru</b>	<b>13</b>
5.1	Architektura instance AS . . . . .	13
5.2	Obsluha požadavku . . . . .	13
5.3	JVT . . . . .	14
5.4	RMI . . . . .	14
5.5	JNDI . . . . .	15
5.6	Object Failover . . . . .	15
<b>6</b>	<b>REST</b>	<b>16</b>
6.1	Principy . . . . .	16
6.2	Výhody HTTP . . . . .	16
6.3	Omezení . . . . .	16
6.4	Zdroj . . . . .	16
6.5	Uniform Resource Identifier . . . . .	17
6.6	Uniform Interface . . . . .	18
6.7	HATEOAS . . . . .	19
6.8	Caching, Revalidation, Concurrency Control . . . . .	19
<b>7</b>	<b>Vysoká dostupnost a výkon</b>	<b>21</b>
7.1	Dobrý výkon . . . . .	21
7.2	Definice . . . . .	21
7.3	Load balancing . . . . .	21
7.4	Typy Load balancerů . . . . .	22
7.5	Round-Robin . . . . .	22
7.6	Nastavení proxy . . . . .	22
7.7	Monitorování . . . . .	22

# 1 Úvod

## 1.1 Hodnocení

5 úkolů, co 2 týdny – minimálně 20b na zápočet, max. 40 bodů. Písemná zkouška ze tří částí po 20 bodech.

## 1.2 Plán

Detaily komunikace, optimalizace výkonu v HTTP, reprezentace dat. Monolitická architektura (aplikační server) vs mikroslužby.

Cloudové služby (Software/Platform/Infrastructure as a service) → především integrace, aplikační server, ESB (enterprise service bus).

## 1.3 Middleware

Technologie se často mění, architektura se nemění zas tak často. Architektura přidává hodnotu do komunikačního systému a pomáhá při integraci aplikací. Jedná se o součást webu 2.0. Svět internetu jde rychle, ale nasazení do praxe bývá pomalejší.

Co může být middleware?

- identity access management (IdAM)
- messaging-oriented middleware (MOM) – *synchronní, asynchronní komunikace*
- protokol (např. SOAP, ale obecně cokoliv pro komunikaci)
- škálovatelnost, load-balancing (nginx)
- monitoring, logování dat, firewall
- stejně jako se snažíme o přepoužitelný kód, tak stejně se snažíme i o přepoužitelné služby
- chceme efektivní aplikace, šetřit náklady

## 2 Architektury informačních systémů


### 2.1 Přehled

**Architektura informačního systému:** popis struktury a chování systému

Mezi základní složky informačního systému patří:

- data, funkce, procesy (doménově závislé, *SaaS*)
- technické detaily:
  - software (*PaaS*)
  - hardware (*IaaS*)

Popis architektury provedeme pomocí **jednotlivých modelů** (datový model, hierarchie funkcí, activity diagram, stavový diagram). **Struktura** je určena daty a funkcemi, **chování** procesy.



Obrázek 1: Základní složky informačního systému

Vývojový koncept: návrh konceptu → obecný koncept → konkrétní implementace. To také závisí na **metodice** (analýza, návrh, implementace, testování, údržba) a **účastnících** (role: koncový uživatel, architekt, vývojář, administrátor).

**Enterprise architektura** se skládá z:

- EIS (executive information systems) – strategické rozhodování (např. do-  
lování dat)

- BSS (business support systems) – systémy na úrovni organizace (např. oddělení financí)
- OSS (operational support systems) – nejnižší úroveň, (např. systém pro kontrolu překročení limitu dat v telekomunikační síti)

a boční systémy OIS (správa dokumentů) a B2B (komunikace mezi firmami).

#### Typy organizace:

- vendor (*poskytovatel*) – dodává aplikaci, produkt (product manager)
- supplier (*dodavatel*) – přizpůsobí produkt na míru (techničtí a solution architekti, adminové)
- customer (*uživatel*) – definuje požadavky

#### Role architektů:

- technický architekt – architektura na technické úrovni
- solution architekt – souvisí s dodavatelem, navrhuje řešení na konkrétní technologii
- enterprise architekt – na vysoké úrovni, znají architekturu aplikací na úrovni aplikační (procesy, datové modely)

## 2.2 Funkce a procesy

#### Klasifikace procesů:

- Level 0 (*business funkce*) – správa zákazníků
- Level 1 (*skupiny procesů*) – správa operací zákazníků
- Level 2 (*core business procesy*) – správa objednávek
- Level 3 (*business aktivita*) – vytvoření objednávky, uzavření objednávky
- Level 4 (*business task*) – vyúčtování objednávky
- Level 5 (*business step*) ...



Obrázek 2: Order to Cash proces u telekomunikačního operátora

## 2.3 Data

**Syntaxe:** datový formát, reprezentace, serializace

- XML, JSON, objektivní datové modely, SQL, YAML ...
- musíme provést validaci, máme zde ale nástroje (XSL, schémata)

**Sémantika:** význam dat v rámci domény, ve které jsou použity, chápeme ji jak přirozeným jazykem, tak skrze data a strukturu.

## 2.4 Integrace aplikací

Existuje integrace vnitropodniková (SOA) a integrace mezi podniky (B2B). Klíčem k integraci je **rozhraní**, to se opět skládá z:

- data – vstup, výstup, struktury pro popis chybových zpráv
- funkce – operace
- procesy – veřejný proces (*"návod k použití"*, *stavový diagram*)
- technické aspekty – IP adresa, protokol

## 2.5 Softwarové architektury

Existuje více úrovní, na kterých rozhraní fungují:

- DBMS (data, funkce, procesy)
- JDBC
- JDO (*Java třídy na data objekty*)
- Domain Object Model

### Separation of Concerns

Při vytváření aplikace můžu mít více vrstev (klient, server; nebo dvě rozdílné komponenty), je třeba se domluvit na rozhraní mezi jednotlivými vrstvami (*manipulace s daty*, *integrita dat*), jednotlivé vrstvy musí být nezávislé.

### Client-server

- centrální server, skupina klientů
- monolitická / dvojvrstvá / třívrstvá ...
- **single point of failure** = pokud server vypadne, máme problém  
→ proto zavedeny ochranné mechanismy

### Peer-to-Peer

- spolehlivý (když uzel selže, jiné uzly zaberou jeho funkci)
- škálovatelný (více uzlů sdílí zátěž – messaging systémy v enterprise systémech)

Existuje více typů architektur:

### Monolitická

Všechny vrstvy na jednom počítači, nepřenosné aplikace na specifický operační systém. Samostatné aplikace, minimální integrace, lokální úložiště dat.

Nevýhodou je složitá údržba a problémy s integritou dat, škálovatelností a výkonem.

## **Dvojvrstvá**

- prezentační a aplikační vrstva jsou odděleny od datové vrstvy
- datová vrstva je na specifickém serveru
- více uživatelů, sdílejících databázi
- SQL + nativní aplikace

Nevýhodou je thick klient, který je náročný na údržbu a integrace na data.

## **Třívrstvá**

Každá vrstva je na specifickém zařízení (tenký klient, komunikuje přes protokol se serverem, ten komunikuje s databází). Ani to ale nestačí ...

## **Middleware**

Přidáváme další middleware vrstvy mezi klienta a server. Problémem je nutnost škálovat jako celek, proto přišla:

## **Architektura mikroslužeb**

Jednotlivé middlewary, aplikace a DB monolity se rozpadají na jednotlivé mikroslužby, které jde již dobře škálovat.

## **2.6 Typy middlewarů**

### **Škálovatelnost**

Zajišťují škálovatelnost, messaging servery, load balancers, proxy servery, reverse proxy

### **Funkční**

Zajišťují více flexibilní integraci, repozitáře, mediátoři (datová/procesová/technická interoperabilita – SOAP), monitorování

### **Bezpečnostní**

Firewally a Gateways

## 3 Architektura služeb

### 3.1 Pohledy na službu

- **business** pohled: služba provede efekt (*v reálném světě*), který přinese reálnou hodnotu uživateli (*např. zakoupení knihy*)
- **konceptuální** pohled: zapouzdření, znovupoužitelnost, loose coupling, abstrakce, composability ...
- **logický** pohled: rozhraní služby, její popis a implementace, zaměření na zprávy nebo zdroje
- pohled z hlediska **software architektury**: business service (externí, zveřejněná funkcionalita) x middleware service (interní, technická, zpracovává požadavky)
- pohled z hlediska **technologie architektury**: REST, GraphQL, XML, RPC, SOAP, gRPC, WebSocket, ...

### 3.2 Rozhraní, popis a implementace

Služba může mít více rozhraní, být naimplementována ve více programovacích jazycích.

- **služba**: rozhraní služby + implementace služby
- **WSDL** služba: popis služby v jazyce WSDL
- **SOAP** služba: rozhraní, které je dostupné přes protokol SOAP
- **REST/RESTful** služba: rozhraní, které splňuje styl architektury REST a HTTP protokol
- **mikroslužba**: sada služeb, které realizují schopnosti aplikace

### 3.3 Public Process

Pracujeme s pomocí stavového diagramu, který popisuje přechod mezi dvěma stavy. To probíhá pomocí operace, která má vstup, podmínky, efekty a výstup.

### 3.4 Principy služeb

- **loose coupling**: když klient volá službu, měl by na ni být co nejméně závislý
- **reusability**: přepoužitelnost, aby mohla být služba využita v co nejvíce situacích
- **contracting**: domluva jednotlivých stran na rozhraní používaném při komunikaci



- **abstraction**: rozhraní by mělo být technologicky nezávislé a oddělené od konkrétní implementace
- **discoverability**: služba by měla být objevitelná včetně návodu k použití
- **composability**: služby lze složit do více komplexních procesů, které lze znova použít jako služby
- **encapsulation**: zapouzdření, implementace je schována a jde vidět jen rozhraní

### 3.5 Integrace a interoperabilita

**Integrace**: spojení aplikací tak, aby mohly sdílet informaci a funkcionality

**Interoperabilita**: schopnost dvou aplikací, aby se chápaly navzájem na úrovni dat (*syntax/struktura*), funkcí, procesů a technických aspektů

### 3.6 SOA

**One-To-One** integrace: špagetová architektura, vše je propojené neřízeně, je v tom nepořádek.

**Many-To-Many** integrace: centrální integrace pomocí Enterprise Service Bus, spravuje jednotlivé vrstvy pomocí **SOA**. (*Špagety jsou zde pořádkem, jen jsou "schované" v ESB*)

SOA je o kultuře, metodologii (*strategie top-down / bottom-up*) a technologii. Jedno z oddělení v IT → ITDelivery řeší **SOA Governance** = propojení jednotlivých systémů.

**Integraci** provedeme buď přes middleware (M:N, ESB, **service-oriented**), přímo (1:1) nebo přes databázi (*datově orientovaná, aplikace D pracuje s databází aplikace B – pozor na integritu dat*).

Mezi těmito způsoby integrace existuje ještě rozdíl v typu dat: webové služby = **real-time** data // **ETL** (*Extract, Transform, Load*): načítání dat v dávkách. SOA využívá hlavně real-time, ale také ETL, třeba v případě selhání, synchronizace všech dat.

### 3.7 ESB

Operační systém → JVM → JDBC, ... → Datové zdroje, JMS → Aplikace. **ESB** je jednou z těchto aplikací, která má sama ještě své podaplikace.

ESB obsahuje služby (sdílené, pro infrastrukturu) i procesy (Technical, Business). **ESB Application** je běžná aplikace na aplikačním serveru. Můžeme zde používat různé integrační vzory.

### 3.8 Integrované vzory

**Synchronní** integrace: jeden socket, čas odpovědi na požadavek je krátký, jednoduchý na implementaci, ale zablokuje mi vlákno, server definuje endpoint

**Asynchronní** integrace: každý požadavek a odpověď má socket zvlášť, jak klient, tak server definují endpoint, čas odpovědi může být dlouhý

**Asynchronní** komunikace pomocí **prostředníka**: máme frontu požadavků na middlewaru, do které zapisují klienti a ze které čtou servery a frontu odpovědí, do které zapisují servery a ze které čtou klienti. Z tohoto vychází Message Queues a Publish / Subscribe, **používané**.

**Asynchronní** komunikace pomocí **pollingu**: klient otevře socket, server mu potvrdí, že může přijímat a klient ho následně polluje a posílá mu požadavky. → typicky na webu (*server nemůže otevřít požadavek*).

---

**Message Broker**: ESB míchá a spojuje standardní i proprietární způsoby přenosu mezi klienty a servery.

**Location transparency**: ESB schová změnu v poloze služeb tak, aby např. změna IP adresy serveru nezměnila klienty, dá se použít i pro load balancing.

**Session Pooling**: ESB udržuje předem daný počet sessionů, které se využívají v runtime, jeden session token může být znovupoužit více instancemi jednoho procesu.

**Dynamic Routing**: ESB vystavuje službu, které přesměruje na různé služby na základě zpráv.

**Message enrichment**: Obohatí zprávu předtím, než zavolá nějakou backend službu (*obohacení zprávy o data zákazníka ze služby dat zákazníků*).

### 3.9 Datové transformace

Aplikace někdy potřebujeme mezi sebou namapovat, využíváme strukturu XSLT, XQuery. Při transformaci je třeba namapovat také jednotlivé identifikátory, k čemuž slouží **mapování klíčů** : CRM-ID → UUID → OMS-ID.

### 3.10 Škálovatelnost

Dělit můžeme 3 způsoby – **X** (škálujeme napříč instancemi (*uživatel 1-100 sem...*)), **Z** (datové roz.) a **Y** (*rozdělením na mikroslužby na základě funkcí*).

Mikroslužby tedy rozdělí aplikaci podle jednotlivých funkcionalit, vytvoří jednotlivé služby, a ty můžou být rozděleny na servery a sdíleny podle potřeby.

**Charakteristika mikroslužeb**: loose coupling (*klient by neměl vědět o tom, kde se služba nachází*), technology-agnostic protokol (*nezávisí na konkrétní technologii*), nezávisle nasaditelné, snadno nahraditelné, zaměřené na informaci (*účetnictví, doporučení*), implementováno více technologií (polyglot), vlastní ji drobný tým.

## 4 Aplikační protokoly

Viz. ISO/OSI model nebo TCP/IP model → zajímá nás právě tato aplikační vrstva, která sdružuje aplikační / prezentační / relační vrstvy. Aplikační protokoly závisí především na **TCP** (ale HTTP/3 už UDP).

Většina aplikací je založena na HTTP protokolu, XML-RPC / SOAP jsou založeny na HTTP, WebSocket a Remote Method Invocation (založeno na Javě).

### 4.1 Socket

**Handshaking**: ustanovení spojení → server poslouchá na IP:port, three-way handshake (SYN, SYN ACK, ACK), výsledkem je **socket** s unikátními zdroje-  
nými / cílovými adresami a porty.

### 4.2 Metriky

Vytváření nových spojení je drahé a omezené **latenci** = doba, kdy putují data mezi klientem a serverem (5 500 km vzdálenost = 28ms), proto chceme optimalizovat spojení → HTTP Keep-alive / pipelining.

TCP Fast Open (**TFO**): při prvním navázání spojení se vytvoří TCP Cookie, při dalším se pak pošle toto cookie a spojení se naváže „okamžitě“ (jen se ověří *cookie*) → redukce až o 15%.

Round trip time (**RTT**): doba od poslání prvního požadavku po přijetí (při navazování spojení: 2x latence, poté: *můžou* se tam počítat i čas zpracování požadavku (**SPT**) na serveru) → u nás **RTT** = 2x latence, **RT** (*response time*) = 2x latence + SPT

### 4.3 Adresace

IP adresa – váže se k rozhraní (eth0, eth1), TCP port je adresou aplikace na jednom rozhraní – více aplikací s různými porty může nalouchat. Existují ale i **aplikační** adresování – například HTTP hlavička Host a domény (*mimo TCP/IP*).

### 4.4 HTTP

Aplikační protokol, základ webu; původně jeden socket, request-response, postupně se ale došlo k možnosti využití více socketů, perzistenci, pipelingu, načítání zdrojů (CSS) z více domén (*domain sharding*).

### 4.5 HTTP Keep-alive

HTTP keep-alive zajišťuje perzistentní spojení: TCP spojení se použije pro více požadavků a odpovědí, čímž **nemusí** dojít k three-way handshake při každém spojení, dochází k **nižší latenci**. Jednotlivé požadavky se obsluhují ve frontě (FIFO) – *request queue*.

## 4.6 HTTP pipelining

HTTP pipelining: optimalizace, která umožňuje poslat v jednom síťovém požadavku za sebou **více** HTTP požadavků, které se následně zpracují paralelně (*response queue*). Pořád zde ale dochází k **head of line blocking** (*dojdou 2 požadavky za sebou, první je ready za 40ms, druhý za 20ms, ale musí čekat, aby došly za sebou*). Podpora HTTP pipelining je **omezená**, protože mechanismus pro posílání více požadavků za sebou je už implementován v HTTP 2.0.

## 4.7 Domain sharding

**Maximální** počet paralelních TCP spojení vůči jednomu originu (protokol; doména; port) pro prohlížeč je **6**. (*tento počet je nastaven kvůli DDoS*)

Tento počet se dá navýšit pomocí tzv. **domain sharding** —> doménu example.com rozdělím na shard1.example.com a shard2.example.com, které ukazují na **stejnou** IP adresu. Na web serveru to rozdělím pomocí konfigurace **VirtualHost**.

## 4.8 State management

Při **prvním** požadavku na server je v odpovědi hlavička **Set-Cookie**, která nastaví klientovi cookie, kterou následně kopíruje při každém požadavku.

**Cookie** obsahuje informace o doméně, maximální době platnosti, URL cestu. Klient pak posílá v hlavičce **Cookie**, pokud nevypršela a sedí doména a cesta. Server pak aktualizuje maximální dobu platnosti při každé odpovědi.

**Stateful server** – server si pamatuje informace o session v neperzistentní paměti serveru (po restartu se smaže).

## 4.9 SOAP

SOAP je framework pro **posílání zpráv**, založený na XML, o vrstvu výše (nabídnou se na HTTP / SMTP / JMS). Obsahuje odesílatele, příjemce a prostředníky. Obsah SOAP zprávy je obálka s hlavičkou a tělem.

**Hlavička** obsahuje **metadata** (informace o směrování, rozšíření WS-\*). **Tělo** obsahuje vlastní **obsah** zprávy a/nebo **chyby**. Poslední částí je **příloha** pro případ binárních dat.

**Endpoint** SOAP služby je síťová **adresa** používaná pro komunikaci pomocí požadavků a odpovědí. U **synchronní** komunikace definuje endpoint pouze služba, u **asynchronní** jak služba, tak klient.

## 4.10 WSDL

Komponenty **WSDL**: informační model (*typy*), sada operací (*jméno, vstup, výstup, chyby*), binding (*způsob přesunu zpráv po síti protokolem*), endpoint (*kde se služba nachází na síti*). WSDL může být **abstraktní** (pouze informační model a sada operací) nebo **konkrétní**.

## 5 Architektura aplikačního serveru

**Aplikační server:** prostředí, kde běží aplikační logika, se kterým komunikuje klient pomocí aplikačního protokolu (*nejčastěji HTTP*).

**Modulární** prostředí poskytující technologii pro enterprise systémy, obsahuje různé **komponenty**, kontejnery (JEE, servlety, JMS), poskytuje služby pro výkon, failover (*přepnutí na funkční komponenty*). Aplikační server **obsahuje** web server v sobě, může být složen z **více** serverů.

Oproti tomu **web server** poskytuje pouze HTTP, zpracovává HTTP požadavky, poskytuje HTTP odpovědi.

### 5.1 Architektura instance AS

Základem je **operační systém**, na tom běží **JVM**. Nad tím je RMI (volání metod), JDBC (databáze), JMS (zprávy), JNDI (naming & directory interface), JTA (transakce), JMX (e-mail) a další **Java technologie**. Na těch stojí **aplikační server**, který obsahuje datové zdroje, JMS server a další **služby pro aplikace** a nad tím stojí každá **aplikace**.

AS je v operačním systému **jeden proces**, který naslouchá na 1 nebo více IP adresách a TCP portech, jedná se o **Java** proces (funguje zde garbage collection, alokace paměti...)

#### Pojmy

**doména** (*skupina serverů se specifickou konfigurací*), **administrační server** (*spravuje doménu*), **managed server** (*spouští aplikace a "objekty" [datové zdroje]*), **cluster** (*skupina managed serverů, obsahují stejnou kopii*), **machine** (*fyzický přístroj a OS, na kterém běží servery*), **node manager** (*proces, který poskytuje přístup k serverům*), **load balancer** (*síťový prvek, který distribuuje požadavky klientů managed serverům*).

#### Servlet

Technologie, která umožní **rozšířit** funkcionality serveru (Java třída, definuje rozhraní, aplikace toto rozhraní implementuje). Jsou používány pro HTTP odpovědi (*HttpServletRequest, HttpServletResponse*).

### 5.2 Obsluha požadavku

**IO:** práce s vstupem nebo výstupem dat, existují dva základní mechanismy implementované různými technologiemi. V tu chvíli, kdy požadavek přijde je vytvořeno nové **vlákno** a řeším dvě úrovně: **inbound** (vstup) a **outbound** (výstup).

## Inbound

**Synchronní I/O:** blokující, pro všechny příchozí požadavky se vytvoří 1 vlákno na 1 požadavek → **nevýhodné**, způsobuje velký počet vláken a nutnost přepínání kontextu

→ **Asynchronní I/O:** předvytvořená vlákna čekají na příchozí požadavky, **obslužná** vlákna jim tyto požadavky přidělují (*jsem schopný to škálovat – jen určitý počet vláken danému požadavku*).

## Outbound

→ **Synchronní I/O:** aktivita **pošle** požadavek, a čeká na odpověď, vlákno je uspané (*blocked*) a čeká (*používá se v kombinaci s JVT*)

**Asynchronní I/O:** po odeslání požadavku se **nečeká** na odpověď, vlákno může být využito na další požadavky, po získání odpovědi se zavolá **callback**, tzv. event loop.

## Komponenty

V rámci aplikačního serveru funguje **muxer**, což je komponenta, která umožňuje zpracovávat komunikaci i přes jiné protokoly (HTTP, RMI...) → předá požadavky do fronty, a z té to potom zpracuje **work manager**.

## 5.3 JVT

Java Virtual Threads = **virtuální vlákna** (*něco jako korutiny*) – vlákna, která JVM mapuje na vlákna operačního systému, ALE! blokující operace **neblokuje** systémová vlákna.

Úlohy jsou obecně CPU bound, nebo I/O bound (omezeny výkonem CPU nebo I/O), na webovém serveru se jedná o úlohy **I/O bound**.

## 5.4 RMI

**Remote Method Invocation:** protokol, který umožňuje komunikaci mezi **Java** aplikacemi → jedna Javovská třída může vzdáleně **zavolat** metody jiné třídy – používá Java Remote Method Protocol. (*!!! RMI není technologicky nezávislý*)

Fáze **vývojová** (*sdílené rozhraní*) → **kompilace** a spuštění → **vyhledání** referencí na jednotlivé objekty v serverovém registru → následně se **volají** metody na serveru.

**Klient** = volá vzdálené metody, **server** = poskytuje vzdálené objekty, **stub** = reprezentace komunikačního objektu na klientovi, **skeleton** = reprezentace komunikačního objektu na serveru, **registr** = komponenta držící stuby.

## 5.5 JNDI

Technologie pro **distribuci objektů** v aplikačním serveru (*hierarchie objektů*): může držet například strom databází, který se nejprve nakonfiguruje, následně se to přiřadí (*nabínduje*) do struktury, nasadí, a jiný klient je pak schopný tento objekt hledat.

Deployment = klient **nasadí** objekt na **jeden** ze serverů a admin server to následně **rozkopíruje** na všechny další servery v rámci clusteru.

## 5.6 Object Failover

Aplikační server obsahuje také **failover** mechanismus = v případě výpadku objektu jsem schopný pomocí tohoto mechanismu přepnout na jiný objekt, který **funguje**. (*klient by neměl poznat, že nastal výpadek*)

## 6 REST

REST není jen protokol, kterým **klient** přistupuje na server, může být využit i pro **crawling**, nebo třeba volání jinou **službou**.

**Representational State Transfer**: přenos stavu, obsahujícího reprezentaci, vytvořen Roy Fieldingem v rámci disertační práce, vychází z technických detailů HTTP (bezstavovost).

Služby, které implementují REST v plné podobě, se nazývají **RESTful**, lidé často **porušují** principy RESTu. REST realizuje **WSA** resource-oriented model.

### 6.1 Principy

**Oddělení zodpovědností** (*separation of concerns*): jsem schopný oddělit vrstvy od sebe (*klient, server*), vývoj může probíhat nezávisle.

**Využívání standardů**, které definují způsob komunikace, na kterých se shodli uživatelé a organizace.

**Open source**, bez licenčních poplatků

### 6.2 Výhody HTTP

**Důvěrnost**: HTTP je rozšířený, známý

**Interoperabilita**: HTTP knihovny nalezneme na všech prostředích, můžeme se zaměřit na jádro problému, nezáleží na konkrétní aplikaci.

**Škálovatelnost**: Webová infrastruktura se dá velmi dobře škálovat (proxy) a cachovat (GET idempotence, safe metody).

### 6.3 Omezení

REST funguje pouze na architektuře **klient-server**. REST je **bezstavový** (*server by neměl mít uloženou žádnou informaci o session*), **cachovatelný** = nutnost cachování, **vrstvený systém** – klient by neměl vědět, s kterou vrstvou za endpointem komunikuje, **jednotné rozhraní** (GET, POST, PUT, PATCH, DELETE) – doménově nezávislé.

### 6.4 Zdroj

Zdroj může být **reálný objekt**, ale také jen abstraktní věc, vzniklá spojením více reálných. Každý zdroj má nějakou svou **reprezentaci** a **identifikátor** tak, aby se k němu klient mohl dostat.



## Přístup ke zdroji

Když chce klient přistoupit ke zdroji, musí nejprve provést **dereferenci URI**, aby zjistil, který protokol chce použít. Následně **přistoupí** k tomuto zdroji, služba předzpracuje požadavek a vytvoří **výslednou reprezentaci**, kterou pošle klientovi zpět. Klient tuto reprezentaci následně **interpretuje**.

## 6.5 Uniform Resource Identifier

URI: identifikuje **zdroj** (*tento zdroj ale nemusí fyzicky existovat*), může to být URL (lokátor) nebo URN (jméno), je **globálně** platný v rámci internetu. Skládá se ze schématu (není protokol), authority, cesty, dotazu a fragmentu.

→ scheme://authority/path?query#fragment

URL: umožní najít zdroj na zadané **lokaci** v síti, každé URL je zároveň URI

URN: Uniform Resource Name: **jméno**, případně obsahující namespace (*isbn: 9877-1222-1414-1222*)

### Resources over Entities

URI často identifikuje zdroj v datovém modelu aplikace: **path** reflektuje datový model (je to graf, URI identifikuje zdroj cestou v tomto grafu).

Oproti tomu **query** umožňuje provést **selekcí** (*?status=valid*) nebo **projekci** (*?properties=id,name*).

**Fragmenty** jsou definovány na základě formátu = v HTML je to tag **id**, v XML ale nic takového není.

### Pojmy

**Capability URL**: krátkodobá URL pro určitý účel (*odkaz ke změně e-mail adresy*)

**URI alias**: dvě různá URI identifikující stejný zdroj

**URI collision**: jedna URI identifikující dva zdroje (*chyba*)

**URI opacity**: content type jako součást URI

**Persistent URL**: i po odstranění dokumentu URL zůstává platné

### Reprezentace zdrojů

Měly by odpovídat Internet Media Types: XML, HTML, JSON, YAML, RDF

Datový formát: **binární** (specifický, komprimovaná data), **textový** (všechny běžné formáty)

**Metadata**: data o zdroji, definován HTTP hlavičkami v odpovědi nebo přímo v datovém formátu (*author, updated*).

**Content-Type:** Accept (požadavek klienta), Content-Type (odpověď serveru), odpovídá IANA (*Internet Assigned Numbers Authority*) media types, zdroj může poskytnout více reprezentací.

**Typické formáty:** text/plain, text/html (*data v přirozeném jazyce*), application/xml, application/json (*specifický formát dané aplikace*) a další specifické zápisy.

**Netypické formáty:** na začátek podtypu dám **x-**, případně **vnd.**, pokud chci vlastní formát – application/x-latex, application/vnd.ms-excel

Když mluvíme o zdroji, myslíme tím **stav zdroje** (aktuální obsah, který se v průběhu času mění).

## 6.6 Uniform Interface

**Jednotné rozhraní** = konečná množina operací, v RESTu se nazývají CRUD (Create – POST/PUT, Read – GET, Update – PUT/PATCH, Delete – DELETE).

Jednotlivé operace **nejsou** doménově specifické: GET nemá sémantiku z pohledu aplikace. (*nejmenuje se to getOrders(), ale GET /orders*)

### Vlastnosti method

**Safe:** nemění stav zdroje, read-only / lookup, lze cachovat (GET)

**Unsafe:** může změnit stav, transakce, unsafe neznamená nebezpečná.

**Idempotence:** zavolání metody na stejném zdroji má **stejný** efekt (*dostane zdroj do stejného stavu stavu*) – GET, PUT i **DELETE**

### Metody

**GET:** získá stav zdroje, hledání, cachovatelné, safe, idempotentní, vrátí typicky 200 OK nebo 404 NOT FOUND.

**PUT:** update (kompletní náhrada) nebo insert (vložení), není safe, ale je idempotentní. Návrátový kód 200 OK nebo 204 No Content při aktualizaci, nebo 201 Created při vložení.

**PATCH:** partial update (částečná náhrada) zdroje, není safe ani idempotentní, návratový kód 200 OK nebo 204 No Content, případně 404 Not Found. Používá se například v **GData** protokolu.

**POST:** vloží nový zdroj, ID je generováno, klient poskytne pouze obsah a URI, není safe ani idempotentní, 201 Created.

**DELETE:** smaže specifický zdroj, není safe, ale je **idempotentní** (*vícenásobné zavolání má stejný efekt – zdroj neexistuje*), návratový kód 200 OK nebo 204 No Content.

**HEAD:** GET jen pro hlavičky, specifický, safe a idempotentní

**OPTIONS:** získá konfiguraci zdrojů (*používáno v protokolu CORS*), safe a idempotentní

## Návratové kódy – chyba 4xx

**400:** obecná chyba na straně klienta, neplatný formát, chyba syntaxe

**404:** zdroj se zadanou adresou neexistuje

**401:** nesprávné přihlašovací údaje (user/pass, API klíč), odpověď by měla obsahovat hlavičku indikující typ autentifikace

**405:** nepovolená metoda HTTP, hlavička Allow umožňuje vypsát podporované metody

**406:** příliš mnoho omezení na typ přijímaného média (Accept)

Při zpracování bychom **měli** používat návratové kódy! Tedy neexistuje nic jako vrátit 200 s payloadem error. Tak stejně je třeba respektovat sémantiku HTTP metod (tedy nic jako GET /orders/?add).

## 6.7 HATEOAS

Název vychází z **hypertextu** (reprezentace zdroje obsahující **odkazy**), odkaz je URI zdroje a to, že aplikujeme přístupovou metodu na zdroj pomocí odkazu je **přechod mezi stavy**. HATEOAS umožňuje bezstavovou implementaci služeb.

**Stateful server:** Stav aplikace je uložen v paměti serveru, klient se identifikuje pomocí cookie.

**Perzistentní úložiště:** obsahuje data aplikace (*např. databáze zboží*)

**Úložiště session:** obsahuje stav aplikace, používá se cookies

**Stateless server:** Nepoužívá paměť serveru, stav se přesouvá pomocí odkazů: POST /orders: obsahuje odkaz /orders/1 → při více serverech je mnohem lepší, protože nemusíme přenášet stav mezi servery.

Odkazy mohou mít hodnotu **rel**, která definuje **sémantiku** operace pod odkazem (*next, previous, self, nebo klidně URI s danou operací*).

Pokud používám HATEOAS, **nemusím** pak kontrolovat **preconditions** u jednotlivých stavů, protože mi odkazy „nedovolí“ se dostat do neplatného stavu.

**Výhody:** průhlednost lokace (zveřejníme jen úvodní odkazy, ostatní se můžou změnit beze změny logiky klienta), loose coupling (klient ví, kam se může dostat přes odkazy), bezstavovost (umožní lepší škálovatelnost).

## 6.8 Caching, Revalidation, Concurrency Control

### Škálovatelnost

Na web přichází velké množství požadavků → chceme škálovat, což lze v RESTu pomocí cachování, revalidace a concurrency control.

### Caching

Cachujeme vždy **statické** zdroje, ale také **dynamické** zdroje (získávané pomocí GET, pomocí hlavičky **Cache-Control**, podle té se pak revaliduje).

**Cache-Control:** *private* (cachuje pouze klient), *public* (cachovat může i proxy), *no-cache* (cachovat se nemá), *no-store* (nesmí se perzistentně ukládat), *no-transform* (nesmí se komprimovat data), **max-age:** platnost cache (v sekundách).

**Last-Modified** a **ETag:** umožní cachovat podle posledního data úpravy nebo podle obsahu zdroje (**Strong** ETag = obsah bit po bitu, např. objednávka, **Weak** ETag = sémantický obsah, definuje aplikace, např. u seznamu objednávek, začíná W/) – hlavičky odpovědi.

**If-Modified-Since** a **If-None-Match** hlavičky požadavku → používá se při revalidaci obsahu (*podmíněný GET* – viz. úkol).

### Concurrency

Používá „optimistické řízení přístupu“ = nezamykám záznam, ale použiji Conditional PUT s hlavičkou **If-Unmodified-Since** (*čas*) a **If-Match** (*ETag*). Odpověď pak může být 200 OK nebo **412 Precondition Failed**. **Diplomka !!!**

### Richardson Maturity Model

Definuje úrovně toho, jak moc je API RESTové:

- 0. úroveň: pouze **XML** (*používám na vše POST, neexistují zdroje*)
- 1. úroveň: **zdroje** a URI (*pořád ale ještě používám na vše POST*)
- 2. úroveň: **HTTP metody** (*používání GET, PUT, DELETE*)
- 3. úroveň: **odkazy** (*HATEOAS*)

## 7 Vysoká dostupnost a výkon

### 7.1 Dobrý výkon

Výkon **je určen** počtem uživatelů, souběžných připojení, zpráv, velikost zpráv, počet služeb, infrastruktura (kapacita, dostupnost, konfigurace).

Vysokého výkonu dosáhneme pomocí **infrastruktury** (škálování, failover), ladění **výkonu** (aplikační server, JVM, OS) a konfigurace služby (paralelní zpracování, optimalizace procesů).

### 7.2 Definice

**Škálování:** vytváření víc instancí systému v případě větší zátěže tak, že koncový uživatel nepozná, že systém používá více uživatelů. Může být **horizontální** (přidávám nové servery) nebo **vertikální** (přidávám další CPU, zvětšuji paměť).

**Dostupnost:** pravděpodobnost, že je služba v daném čase funkční (*99.9987 % = služba má výpadek 44 sekund ročně*). **LSA:** zaručuje dostupnost služby, jinak zákazník dostane slevu.

**Vysoká dostupnost:** schopnost systému se škálovat (*když jedna instance spadne, operace budou přeměřovány na jinou*), **application failover:** když selže jedna komponenta, překopíruje se práce na jinou – musí to být ale možné

Metrika **doba odpovědi:** kolik času zabere od prvního zadání domény do návratu odpovědi: DNS lookup (*→ nepoužívat doménová jména, ale rovnou DNS*), TCP handshaking (*→ používat perzistentní připojení*), RTT (*někdy lze ignorovat*) a samotný server processing time

Další metrika je pak **queries per second** (na straně serveru).

### 7.3 Load balancing

**Rozložení zátěže** více instancím aplikace (*na různých strojích, sdílení zátěže*).

DNS-based load balancer (*DNS round robin*) → NAT-based load balancer → Reverse-proxy load balancer → klientský load balancer.

#### DNS-based

Na **jeden** DNS záznam je přiřazeno **více** IP adres, DNS systém přiděluje algoritmem Round Robin adresy ze seznamu. Velmi jednoduché, ale není možnost monitorovat status a zdraví serverů.

#### Reverse Proxy (nginx)

Load Balancer (na úrovni **TCP** a **HTTP**) dostane příchozí požadavek a vybere instanci aplikace, které **přepoše** požadavek. Následně zpětně dostane odpověď a tu **vrátí** zpět. Jednotlivé instance obsahují také **endpointy** pro kontrolu zdraví (*stavu*) aplikace.

**Sticky session:** load balancer jednomu konkrétnímu uživateli zajišťuje, že bude vždy komunikovat s jedním **konkrétním** serverem (*aby mu nezmizela session* → *pasivní cookie, nebo aktivní = load balancer přidá vlastní cookie*).

## 7.4 Typy Load balancerů

Softwarové: Apache (*mod\_proxy\_balancer*), **NGINX**, obsahuje **sticky sessions**, různé možnosti konfigurace, plug-iny nebo hardwarové.

## 7.5 Round-Robin

Pokud existuje **identifikátor** sessionu, použije se **stejný** server. Jinak se pošle server na **další** server v pořadí (*id serveru, plus modulo*) a zapamatuje si identifikátor sessionu.

## 7.6 Nastavení proxy

Toto ale nemusí fungovat vždy, server může být přetížen. Proto se používá také metrika **least connections** (požadavek se pošle na server, který je nejméně zatížený) nebo **least time** (požadavek se pošle na server s nejkratší průměrnou dobou odezvy a nejmenším počtem připojení).

Zároveň můžeme omezit **maximální počet** připojení (throttling), nastavit kapacitu, nebo nastavit serveru pomalý začátek (*úmyslné timeouty na začátku, aby server nebyl hned zahlcen*).

### Sticky cookie

Cookie je definováno přímo load balancerem, může ho tedy v případě výpadku přeposlat na jiný server, případně **sticky learn** = load balancer rozpozná cookie od uživatele a využije ho.

### Session state persistence

Jinou možností je si ukládat informace o session přímo do databáze, ke které pak přistupují jednotlivé servery, a není tedy třeba používat sticky sessions v load balanceru.

## 7.7 Monitorování

Potřebujeme sbírat data o běhu systému, filtrovat je, ukládat, zobrazovat a následně **ladit**. Metriky můžeme získat z aplikačního serveru (přístupové logy, server logy), operačního systému (otevřené sockety, paměť, počet přepnutí kontextu, I/O výkon) a databáze.